

Ejercicio de Feedback 2 Detección Inteligente de Arritmias con Datos de ECG y Aprendizaje Automático

Matemáticas y Estadística para la IA

1. Descripción del caso

El avance de los dispositivos **wearables** y la proliferación de soluciones de **monitorización remota de la salud** han abierto la puerta al desarrollo de sistemas inteligentes capaces de analizar señales fisiológicas en tiempo real. En particular, los **electrocardiogramas (ECG)** capturados por sensores portátiles permiten detectar irregularidades en el ritmo cardíaco con fines preventivos.

En este contexto, se plantea un reto aplicado:

Desarrollar un modelo inteligente que clasifique latidos cardíacos individuales como normales o anómalos, con el fin de integrarlo en un sistema de alerta para smartwatches, enfocado a usuarios mayores de 60 años.

2. Objetivos de este ejercicio de feedback

El trabajo tiene como finalidad:

1. Explorar, limpiar e interpretar señales biomédicas en formato multivariable.
2. Analizar estadísticamente los datos (tendencia central, dispersión, forma).
3. Aplicar **PCA** para reducir dimensionalidad y facilitar el análisis visual.
4. Entrenar un modelo de **clasificación supervisada** que distinga entre latidos normales y anómalos.
5. Evaluar el rendimiento del modelo con métricas estándar (precisión, recall, F1).
6. Calcular probabilidades condicionales aplicando el **Teorema de Bayes**.
7. Redactar un informe final técnico y profesional como si fuera destinado a un equipo médico.

3. Dataset

Trabajarás con el conjunto de datos **ECG Heartbeat Categorization Dataset**, publicado por Shayan Fazeli y colaboradores en Kaggle. Este dataset está basado en dos bases clínicas muy reconocidas: el **MIT-BIH Arrhythmia Dataset** y el **PTB Diagnostic ECG Database**.

Nombre del Dataset: ECG Heartbeat Categorization Dataset

Descarga directa en la pagina de Kaggle, ademas de contener más información del caso: <https://www.kaggle.com/datasets/shayanfazeli/heartbeat>

Archivo principal:

Trabajarás con el conjunto de datos **ECG Heartbeat Categorization Dataset**, que incluye dos archivos principales:

- **mitbih_train.csv**: contiene **87,554 registros**, correspondientes a latidos cardíacos utilizados para el entrenamiento de modelos.
- **mitbih_test.csv**: contiene **21,892 registros**, utilizados típicamente para evaluar el rendimiento del modelo.

Cada fila en ambos archivos representa un **latido cardíaco individual**, compuesto por:

- **187 valores numéricos**, que corresponden a la señal de ECG muestreada a 125 Hz.
- **1 etiqueta de clase** (columna 188), que indica el tipo de latido.

Total del conjunto completo: 109,446 registros.

Las **clases** se corresponden con:

- **0**: Latido normal (N)
- **1**: Latido supraventricular (S)
- **2**: Latido ventricular (V)
- **3**: Latido de fusión (F)
- **4**: Ruido (Q)

Todos los latidos han sido **segmentados, recortados y normalizados** a una longitud fija de 187 muestras, y están etiquetados manualmente.

Características técnicas:

- Frecuencia de muestreo: 125 Hz
- **Formato**: CSV, listo para ser usado con pandas o NumPy
- **Dimensiones**: Cada latido tiene exactamente 188 valores → 187 de la señal + 1 etiqueta

4. ¿Por qué es interesante este Dataset?

El conjunto de datos **ECG Heartbeat Categorization Dataset** es especialmente interesante porque permite trabajar con **datos biomédicos reales**, preprocesados y etiquetados, simulando un escenario clínico de alta relevancia: la **detección de arritmias cardíacas** a partir de señales captadas por sensores portátiles como los de un smartwatch.

Desde el punto de vista de la asignatura, este dataset ofrece una oportunidad ideal para: Aplicar conocimientos de estadística y matemáticas:

- **Estadística descriptiva:** analizar formas de onda mediante medidas de tendencia central, dispersión, simetría y curtosis.
- **Visualización y análisis de distribuciones:** histogramas, boxplots y análisis de clases desbalanceadas.
- **Reducción de dimensionalidad** con PCA: ideal para representar gráficamente datos de alta dimensión (187 valores por latido).
- **Modelado predictivo básico:** entrenar modelos supervisados como regresión logística o árboles de decisión con fundamentos matemáticos.
- **Probabilidad y Teorema de Bayes:** estimar la probabilidad condicional de que un latido pertenezca a una clase dada cierta evidencia observada en la señal.

Ventajas didácticas clave:

- Dataset listo para usar (CSV) y de fácil carga en Python.
- Casos multiclase con representación realista de ruido y desbalance.
- Alta aplicabilidad práctica en sectores como salud digital, wearables e IA para medicina.
- Permite conectar el análisis estadístico con el desarrollo de soluciones de IA reales e interpretables.

Este caso simula el reto de construir un modelo que, en un entorno clínico, ayude a un profesional médico a detectar automáticamente ritmos cardíacos anómalos, con base en evidencia estadística sólida y justificada.

4. Actividades y Retos

Para resolver este ejercicio de forma completa y rigurosa, deberás realizar las siguientes actividades. Cada una corresponde a una parte del proceso típico en un flujo de análisis estadístico aplicado con herramientas de IA.

1. Exploración Inicial y Análisis Descriptivo (EDA)

Puntuación: 20%

Objetivo: Conocer la estructura del dataset y detectar patrones, anomalías o características relevantes.

Tareas:

- Cargar el archivo `mitbih_train.csv`.
- Visualizar y analizar la distribución de clases.
- Calcular estadísticas básicas de tendencia central y dispersión (media, mediana, moda, rango, varianza, percentiles...).
- Graficar boxplots, histogramas, y algunas señales típicas por clase.
- Comentar patrones relevantes: ¿qué formas de onda parecen similares? ¿cuáles son distintas?

Entregable:

Gráficos + resumen interpretativo en texto (máx. 2 páginas)

2. Reducción de Dimensionalidad (PCA)

Puntuación: 20%

Objetivo: Identificar patrones, relaciones o estructuras en el espacio reducido de características.

Tareas:

- Aplicar PCA sobre los 187 valores de señal.
- Visualizar los dos primeros componentes en un scatter plot con colores por clase.
- Calcular la varianza explicada por los primeros componentes.
- Comentar si hay agrupamientos o solapamientos entre clases.

Entregable:

Gráficos + interpretación (máx. 1 página).

3. Modelos de Clasificación

Puntuación: 30%

Objetivo: Entrenar al menos dos modelos de clasificación supervisada con base estadística, aplicados a los datos de latidos.

Tareas:

- Seleccionar modelos básicos como (por ejemplo, se pueden aplicar más):
 - Regresión logística
 - Árbol de decisión
 - Clasificador bayesiano
 - Red neuronal
- Evaluar el rendimiento con:
 - Matriz de confusión
 - Precisión y recall
 - F1-score
- Comparar los modelos y argumentar cuál funciona mejor y por qué (balance entre clases, rendimiento global...).

Entregable:

Tabla resumen + gráficos + análisis comparativo (máx. 2 páginas).

4. Probabilidades Condicionales y Teorema de Bayes

Puntuación: 15%

Objetivo: Aplicar el teorema de Bayes en un contexto real de clasificación para estimar la probabilidad de que un latido sea anómalo dado cierto patrón de señal.

Tareas:

- Calcular probabilidades marginales y condicionales para dos clases (0 vs 2 por ejemplo).
- Estimar manualmente:
 - $P(\text{latido} = \text{clase 2} \mid \text{presencia de patrón X})$
 - $P(\text{latido} = \text{clase 0} \mid \text{presencia de patrón X})$
- Justificar resultados e interpretar su uso clínico (falsos positivos, sensibilidad al riesgo).

Entregable:

Cálculos + interpretación de resultados (máx. 1 página).

5. Informe Final

Puntuación: 15%

Objetivo: Elaborar un documento técnico-resumen con los hallazgos principales del caso, como si fuese dirigido a un equipo técnico de producto o a un cardiólogo interesado en IA.

Criterios:

- Claridad y organización
- Coherencia entre análisis, visualizaciones y conclusiones
- Justificación de decisiones estadísticas tomadas

6. Instrucciones de Entrega

Informe en PDF (máx. 8 páginas)

- Formato:
 - PDF con informe final técnico
 - Notebook Jupyter (comentado y estructurado)
- Nombre de archivos:
 - Feedback_ECG_ApellidosNombre.pdf
 - Feedback_ECG_ApellidosNombre.ipynb
- **Fecha límite:** viernes **23 de enero del 2026**
- **Entrega:** Aula Virtual → Sección Ejercicio Feedback

7. Referencias

Fazeli, S., Kachuee, M., & Sarrafzadeh, M. (2018). *ECG Heartbeat Classification: A Deep Transferable Representation*. arXiv preprint arXiv:1805.00794. <https://arxiv.org/abs/1805.00794>

Kachuee, M., Fazeli, S., & Sarrafzadeh, M. (2018). ECG Heartbeat Categorization Dataset. *Kaggle*. <https://www.kaggle.com/datasets/shayanfazeli/heartbeat>

Universidad Alfonso X el Sabio (2024). Material docente de Matemáticas y Estadística para la IA. Unidades disponible en Aula Virtual UAX.



UAX.COM