

Feedback_default_blancohugo

Explicabilidad de Modelos de Clasificación con SHAP

Calibración, métricas y explicabilidad de modelos de IA

1. Introducción

En este trabajo se desarrolla un pipeline completo de aprendizaje automático orientado a la predicción de impago en clientes de tarjetas de crédito. El objetivo principal consiste en analizar el comportamiento financiero de los clientes y construir modelos capaces de identificar perfiles con mayor riesgo de default.

Para ello se ha utilizado el dataset “Default of Credit Card Clients”, disponible en el repositorio UCI Machine Learning Repository. Este conjunto de datos contiene información de 30.000 clientes de una entidad financiera de Taiwán, incluyendo variables demográficas, historial de pagos, importes facturados y pagos realizados.

A lo largo del trabajo se realiza un análisis exploratorio de los datos (EDA), el entrenamiento y comparación de distintos modelos supervisados, así como un análisis de explicabilidad utilizando SHAP para interpretar las decisiones del modelo seleccionado.

2. Exploración Inicial y Análisis Descriptivo (EDA)

2.1 Carga y limpieza del dataset

El dataset fue cargado desde un archivo Excel utilizando pandas. Posteriormente, se realizó una limpieza básica de variables categóricas.

Se detectaron valores anómalos en las variables EDUCATION y MARRIAGE:


- En EDUCATION aparecían las categorías 0, 5 y 6, que fueron agrupadas en la categoría 4 (“otros”).
- En MARRIAGE aparecía la categoría 0, que también fue agrupada dentro de “otros”.

Además, se eliminó la columna ID por no aportar valor predictivo al modelo.

2.2 Distribución de LIMIT_BAL

La variable LIMIT_BAL presenta una distribución claramente sesgada hacia valores bajos y medios. La mayoría de los clientes poseen límites de crédito relativamente reducidos, mientras que existe una minoría con límites muy elevados.


También se observan valores extremos, indicando una elevada dispersión en la capacidad crediticia de los clientes.



2.3 Distribución de AGE

La variable AGE muestra una distribución más estable, concentrándose principalmente entre los 25 y 40 años.


No se observan valores atípicos extremos y la distribución presenta una ligera asimetría hacia edades más altas.



2.4 Distribución de la variable objetivo

La variable objetivo presenta un desbalance importante entre clases. La mayoría de los registros pertenecen a clientes que no incurrieron en impago (default = 0), mientras que la clase de impago representa una proporción significativamente menor.


Este desbalance puede afectar negativamente a la capacidad del modelo para detectar correctamente la clase minoritaria.



2.5 Relación entre LIMIT_BAL y default

El análisis mediante boxplot muestra que los clientes que realizaron impago suelen presentar límites de crédito inferiores respecto a los clientes que no incurrieron en default.

Además, el grupo sin impago presenta una mayor dispersión y límites de crédito considerablemente más elevados.



3. Entrenamiento y Evaluación de Modelos

3.1 Modelos utilizados

Se entrenaron tres modelos supervisados de clasificación:

- Logistic Regression
- Random Forest Classifier
- Gradient Boosting Classifier

El conjunto de datos fue dividido en entrenamiento y prueba utilizando un 80% para entrenamiento y un 20% para test.

3.2 Resultados obtenidos

Modelo	AUC	F1-score clase 1
Logistic Regression	0.7079	0.36
Random Forest	0.7572	0.46

Gradient Boosting 0.7790 0.47

3.3 Interpretación de resultados

La regresión logística obtuvo el rendimiento más limitado, especialmente en la detección de la clase minoritaria, mostrando un recall y F1-score inferiores al resto de modelos.

Los modelos basados en árboles mejoraron significativamente el rendimiento global del sistema, siendo capaces de capturar relaciones no lineales entre variables.

Gradient Boosting obtuvo el mejor equilibrio entre AUC y F1-score para la clase minoritaria, alcanzando un AUC de 0.7790 y un F1-score de 0.47 para la clase de impago.

Por este motivo, se seleccionó Gradient Boosting como modelo final para la fase de explicabilidad.

4. Explicabilidad del Modelo con SHAP


4.1 Summary Plot

Se utilizó SHAP para interpretar las decisiones del modelo Gradient Boosting.

El summary plot muestra que las variables más relevantes para la predicción son PAY_0, LIMIT_BAL, BILL_AMT1 y PAY_2.

Las variables relacionadas con retrasos recientes en pagos tienen un impacto muy importante sobre el aumento del riesgo de impago. En particular, valores elevados de PAY_0 incrementan significativamente la probabilidad de default.

Por otro lado, límites de crédito elevados tienden a reducir el riesgo de impago.




4.2 Waterfall Plot

El waterfall plot permite interpretar la predicción individual de un cliente concreto.

En el ejemplo analizado, LIMIT_BAL incrementa el riesgo estimado de impago, mientras que variables como PAY_0 y PAY_AMT1 reducen parcialmente dicho riesgo.

La visualización permite observar cómo cada variable empuja la predicción hacia una mayor o menor probabilidad de default.

Este tipo de interpretabilidad resulta especialmente relevante en contextos financieros, donde es importante justificar las decisiones automatizadas.



5. Reflexión Crítica

El modelo Gradient Boosting obtiene un rendimiento razonable, alcanzando una accuracy de 0.82 y un AUC de 0.7790. Sin embargo, el rendimiento sobre la clase minoritaria continúa siendo limitado.

El recall obtenido para la clase de impago es relativamente bajo, lo que implica que el modelo no consigue identificar correctamente todos los clientes con riesgo real de default.

Esta limitación está directamente relacionada con el desbalance de clases presente en el dataset.

Para mejorar el rendimiento podrían aplicarse técnicas de balanceo como SMOTE o undersampling, así como ajustes del umbral de decisión para priorizar una mayor detección de clientes con riesgo.

También sería interesante utilizar algoritmos más avanzados como XGBoost o LightGBM, además de realizar procesos de optimización de hiperparámetros.

A pesar de estas limitaciones, el modelo desarrollado constituye una aproximación válida para sistemas de scoring financiero y permite interpretar de forma transparente las decisiones tomadas.

6. Conclusiones

En este trabajo se ha desarrollado un pipeline completo de clasificación para predecir el riesgo de impago en clientes de tarjetas de crédito.

Se realizó un análisis exploratorio inicial, una limpieza básica de datos, el entrenamiento y comparación de distintos modelos supervisados y un análisis de explicabilidad utilizando SHAP.

El modelo Gradient Boosting fue seleccionado como mejor alternativa al obtener el mejor equilibrio entre capacidad discriminativa y rendimiento sobre la clase minoritaria.

Finalmente, el análisis de SHAP permitió identificar que el historial reciente de pagos y el límite de crédito son las variables más relevantes para explicar el riesgo de impago.

Los resultados obtenidos muestran que la explicabilidad resulta fundamental en aplicaciones financieras, ya que permite comprender y justificar las decisiones automáticas tomadas por modelos de inteligencia artificial.